



# MODELO PREDITIVO DE CHURN DE ENTREGADORES

EMPRESA RAPPI

## Controle do Documento

### Histórico de revisões

Data	Autor	Versão	Resumo da atividade
08/08/2022	-Alysson Cordeiro; -Bruno Moitinho Leão; -Frederico Schur; -Israel Carvalho; -Luiz Carlos da Silva Júnior; -Stefano Tosi Butori.	1.0	Criação do documento
09/08/2022	Todos	1.1	Atualização dos tópicos 4.1.1 a 4.1.5
10/08/2022	Todos	1.2	Atualização do tópico 4.2

# Sumário

<b>1. Introdução</b>	<b>5</b>
<b>2. Objetivos e Justificativa</b>	<b>6</b>
2.1. Objetivos	6
2.2. Justificativa	6
<b>3. Metodologia</b>	<b>7</b>
3.1. CRISP-DM	7
3.2. Ferramentas	7
3.3. Principais técnicas empregadas	7
<b>4. Desenvolvimento e Resultados</b>	<b>8</b>
4.1. Compreensão do Problema	8
4.1.1. Contexto da indústria	8
4.1.2. Análise SWOT	11
4.1.3. Planejamento Geral da Solução	12
4.1.4. Value Proposition Canvas	13
4.1.5. Matriz de Riscos	15
4.1.6. Personas	17
4.1.7. Jornadas do Usuário	17
4.2. Compreensão dos Dados	18
4.2.1. Descrição Geral dos Dados	18
4.2.2. Estatística Descritiva dos Dados	20
4.2.3. Descrição da Predição Desejada ("Target")	20
4.3. Preparação dos Dados	21
4.4. Modelagem	22
4.5. Avaliação	23
4.6. Comparação de Modelos	24
<b>5. Conclusões e Recomendações</b>	<b>25</b>



# 1. Introdução

Apresente de forma sucinta o parceiro de negócio, seu porte, local, área de atuação e posicionamento no mercado. Maiores detalhes deverão ser descritos na seção 4

Descreva resumidamente o problema a ser resolvido (sem ainda mencionar a solução).

Caso utilize citações ao longo desse documento, consulte a norma ABNT NBR 10520. Sugerimos o uso do sistema autor-data para citações.

## 2. Objetivos e Justificativa

### 2.1. Objetivos

Descreva resumidamente os objetivos gerais e específicos do seu parceiro de negócios

### 2.2. Justificativa

Faça uma breve defesa de sua proposta de solução, escreva sobre seus potenciais, seus benefícios e como ela se diferencia.

## 3. Metodologia

Descreva as etapas metodológicas que foram utilizadas para o desenvolvimento, citando o referencial teórico. Você deve apenas enunciar os métodos, sem dizer ainda como ele foi aplicado e quais resultados obtidos.

### 3.1. CRISP-DM

Descreva brevemente a metodologia CRISP-DM e suas etapas de processo

### 3.2. Ferramentas

Descreva brevemente as ferramentas utilizadas e seus papéis (Google Collaboratory)

### 3.3. Principais técnicas empregadas

Descreva brevemente as principais técnicas empregadas, algoritmos e seus benefícios

## 4. Desenvolvimento e Resultados

### 4.1. Compreensão do Problema

#### 4.1.1. Contexto da indústria

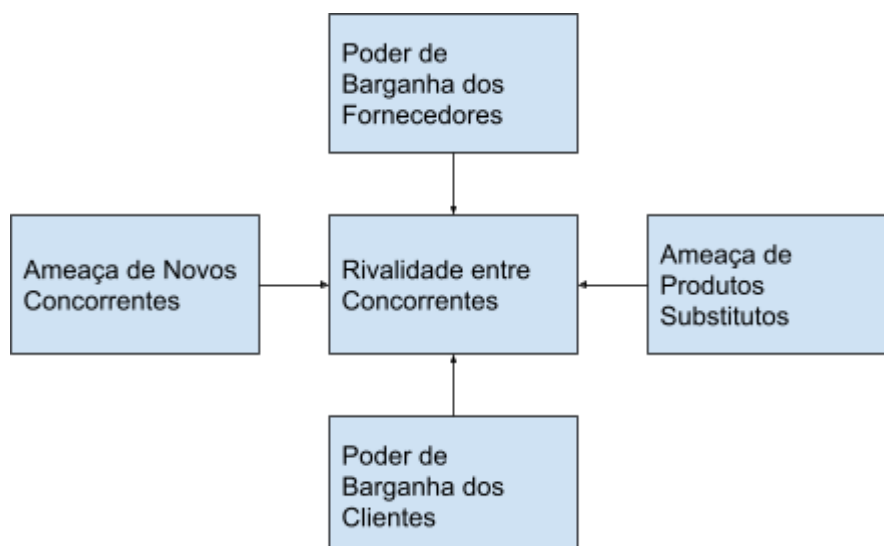
O modelo de negócio da Rappi é do tipo plataforma multilateral, pois conecta estabelecimentos comerciais a entregadores e a clientes que precisam de serviços de entrega (delivery). A plataforma disponibiliza cardápios e menus das mais variadas instalações - restaurantes, lojas de todos os ramos, supermercados, entre outros.

Além do mais, a concorrência da companhia é bastante abrangente, porque, de certa forma, inclui desde toda e qualquer empresa de delivery (especialmente os aplicativos de entregas, como, por exemplo, IFood, Loggi, Glovo e Lalamove) e até os e-commerces gigantes, como a Amazon; esse de uma forma indireta.

Vale ressaltar, ademais, que o delivery é uma das principais tendências do mercado após o isolamento social da pandemia do COVID-19 em 2020. E ele tende apenas se fortalecer. No entanto, as entregas estão deixando de ser focadas apenas em comida para alcançar novos patamares, como medicamentos e outros produtos diversos, por exemplo. Além disso, esse tipo de mercado está optando por uma prática mais sustentável, como, por exemplo, ajudar o consumidor a identificar restaurantes que usam menos plásticos em seus produtos e tornar grande parte dos pedidos neutros em carbono (CO2) no país.

Utilizaremos a análise das 5 Forças de Porter para entender melhor a indústria de delivery por aplicativo.





### **Ameaça de Novos Concorrentes:**

Durante a pandemia, 89% dos estabelecimentos passaram a utilizar o delivery como uma solução para disponibilizar seus produtos (grande crescimento do mercado). Entretanto, o alto custo operacional gerado pela operação no mercado de delivery acaba dificultando a instalação de novas empresas, além da manutenção de empresas já estabelecidas, como por exemplo o recente caso do Uber Eats (alto custo operacional).

### **Poder de Barganha dos Clientes:**

Por mais que houve um aumento expressivo no setor de delivery impulsionado principalmente pela necessidade das empresas de se adequarem às restrições impostas ao SARS-CoV-2 (coronavírus) e, também, considerando o cenário macroeconômico dos últimos meses, é possível notar um aumento da inflação e, conseqüentemente, uma diminuição no grau de consumo em diversas áreas da economia, incluindo a de delivery. Logo, é razoável inferir que o poder de barganha dos consumidores nesse cenário é relativamente baixo, visto que diante de um cenário em que há uma alta de preços em toda a economia, os consumidores não conseguirão “barganhar” por preços menores.

### **Ameaça de Produtos Substitutos:**

Não há muitos produtos substitutos para o delivery por aplicativo. A opção alternativa mais evidente seria a entrega efetivada diretamente em contato com o restaurante, eliminando a intermediação via aplicativo. Essa opção não oferece a comodidade de ver o cardápio de opções pelo aplicativo e apresenta o incômodo de ter que pesquisar um restaurante e conversar com um atendente por telefone.

### **Poder de Barganha dos Fornecedores:**

Tendo em vista todo o cenário descrito nos tópicos anteriores, é possível concluir que o poder de barganha dos fornecedores é expressivo, uma vez que eles controlam em qual marketplace estarão disponíveis. Por outro lado, contratos de exclusividade podem restringir a capacidade de escolha dos fornecedores e reduzir o poder de barganha destes.

### **Rivalidade entre Concorrentes:**

A rivalidade entre os concorrentes nesse setor é extremamente alta em consequência do constante esforço para garantirem uma operação de qualidade, além de um grande market share. É comum que empresas desse setor gastem seus recursos de caixa para crescer, e, conseqüentemente, acabam não dando lucro.

#### 4.1.2. Análise SWOT

<p style="text-align: center;"><b>Strengths (Forças)</b></p> <ul style="list-style-type: none"> <li>- Entrega turbo em 10 minutos</li> <li>- Alguns parceiros exclusivos</li> <li>- Parceria com players de outros setores (ex: HBOMax)</li> <li>- Presença substancial na América Latina</li> <li>- Atuação em outros setores, como o financeiro (RappiBank)</li> </ul>	<p style="text-align: center;"><b>Weakness (Fraquezas)</b></p> <ul style="list-style-type: none"> <li>- Dependência de entregadores que não são CLT</li> <li>- A função de rastreo da entrega não é consistente</li> <li>- “Churn” elevado de entregadores</li> </ul>
<p style="text-align: center;"><b>Opportunities (Oportunidades)</b></p> <ul style="list-style-type: none"> <li>- Saída recente de um player relevante, abrindo assim uma nova fatia do mercado</li> <li>- Aumento da demanda por delivery de diversos produtos</li> </ul>	<p style="text-align: center;"><b>Threats (Ameaças)</b></p> <ul style="list-style-type: none"> <li>- Mercado bastante competitivo</li> <li>- Instabilidade de fatores externos que afetam os entregadores, como preço da gasolina, variações climáticas ou feriados</li> </ul>

### 4.1.3. Planejamento Geral da Solução

**Dados disponíveis:** A Rappi disponibilizou até o momento uma série de arquivos CSV, com o conteúdo detalhado de forma mais extensiva no tópico 4.2.1 deste documento. Os dados desses arquivos, conforme informações repassadas pelo cliente em entrevista, foram obtidos por meio do aplicativo de delivery.

Esses arquivos incluem informações diversas sobre os entregadores, como a taxa de aceitação dos pedidos, receita mensal, reclamações sobre pedidos, data de criação das contas que sofreram "churn", registro de suspensões e avisos, número de ordens, tempo que o entregador ficou "online", ordens devolvidas e dados gerais.

**Solução proposta:** Pretendemos desenvolver um modelo preditivo para classificar se um entregador irá permanecer ou sair ("churn") da plataforma Rappi. Como efeito secundário, podemos verificar a probabilidade que o modelo entende que aquele resultado se concretizará e os fatores ("features") que o modelo considera para a classificação geral.

**Tipo de tarefa (regressão ou classificação):** a predição de "churn" é essencialmente uma tarefa de *classificação binária* - o objetivo é informar se os entregadores irão: (i) permanecer; ou (ii) sair ("churn") da plataforma dentro de um período determinado.

**Forma de utilização da solução proposta:** a Rappi poderá usar o modelo para classificar se um entregador está propenso a sair da plataforma e, se desejar, dedicar mais esforços para manter esse entregador na plataforma.

**Benefícios trazidos pela solução proposta:** o modelo pode permitir uma visualização rápida dos entregadores mais inclinados a parar de usar a plataforma em breve, levar a um maior entendimento dos fatores que podem causar esse evento, facilitar o diálogo e reduzir a taxa de "churn" para um patamar adequado.

**Critério de sucesso e métricas de avaliação:** entendemos que o modelo deve apresentar certa probabilidade de acerto em suas predições. Para tanto, utilizamos como métricas de avaliação:

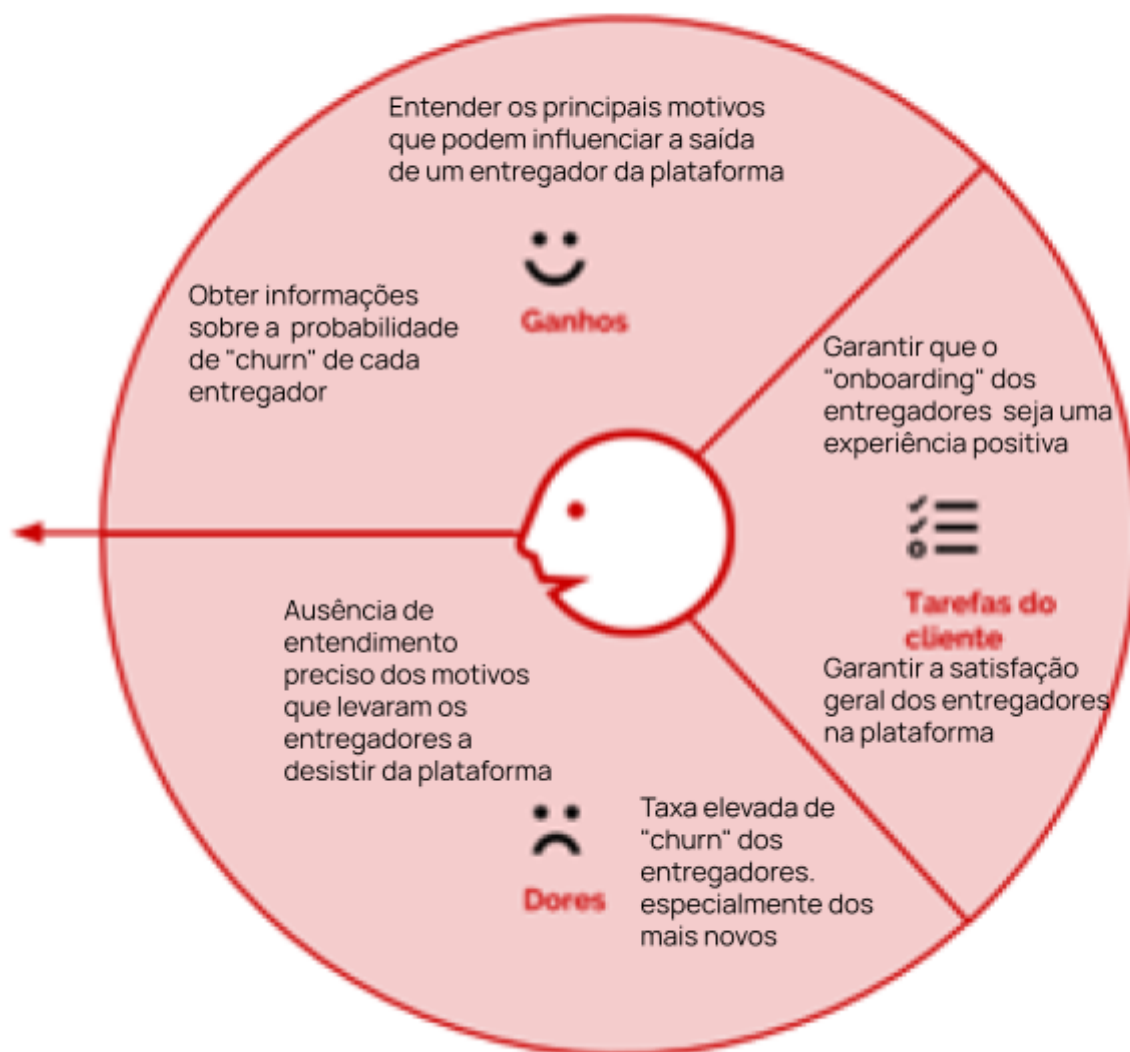
- A. acurácia ("accuracy"), a razão entre o número de predição corretas e o número total de predições, fornece um indicador de confiabilidade geral do modelo:
 
$$\frac{\text{Positivos Verdadeiros} + \text{Negativos Verdadeiros}}{\text{Positivos Verdadeiros} + \text{Negativos Verdadeiros} + \text{Positivos Falsos} + \text{Negativos Falsos}};$$
- B. precisão ("precision"), a confiabilidade do modelo quando ele aponta que um resultado é positivo:
 
$$\frac{\text{Positivos Verdadeiros}}{\text{Positivos Verdadeiros} + \text{Positivos Falsos}};$$
- C. revocação ("recall"), a confiabilidade do modelo em detectar *todos* os resultados positivos corretamente:
 
$$\frac{\text{Positivos Verdadeiros}}{\text{Positivos Verdadeiros} + \text{Negativos Falsos}};$$

#### 4.1.4. Value Proposition Canvas

## Proposta de Valor



# Perfil do Cliente



## 4.1.5. Matriz de Riscos

		Ameaças				
P r o b a b i l i d a d e	90%			Bugs no código do modelo preditivo		
	70%					
	50%			Imprecisão / inconsistência dos dados usados para análise		
	30%			Não ter dados relevantes para solucionar o problema	Modelo ter uma precisão ou acurácia baixa	
	10%					Sistema exigir muita capacidade computacional
		Muito baixo	Baixo	Moderado	Alto	Muito alto
		Impacto				

		Oportunidades				
P r o b a b i l i d a d e	90%					
	70%	Concorrência não possuir ferramenta que mapeie o churn	Sistema prevê corretamente a chance de saída dos RTs	Bom volume de dados para treinar o modelo		
	50%					
	30%					
	10%					
		Muito alto	Alto	Moderado	Baixo	Muito baixo
		Impacto				



## 4.1.6. Personas

### José González



AGE	29
EDUCATION	Gestão da Tecnologia da Informação
STATUS	Solteiro
OCCUPATION	Diretor de Operações
LOCATION	São Paulo
TECH LITERTE	Alta

“Estou acostumado com atendimento ao cliente, principalmente entender o comportamento do cliente em relação ao produto.

#### Personalidade

Comunicativo

Simpático

#### Biografia

Mora em São Paulo, na capital. Graduiu-se em Sistemas da Informação, terminou sua pós em Gestão de TI em 2020. Se especializou em customer experience. Devido a sua especialização, foi promovido recentemente em uma empresa de Delivery. É um homem comunicativo, empreendedor e está sempre antenado para as novas tendências e oportunidades de mercado. González atualmente está solteiro e gosta de viajar sempre que pode.

#### Necessidades

- Entender o motivo do elevado nível da saída de entregadores de aplicativo da empresa.
- Pretende utilizar um modelo preditivo para classificar se um entregador permanecerá ou sairá da companhia.

#### Frustração

- Baixo contato com entregadores de delivery.
- Possui dificuldade em analisar a probabilidade de “churn” dos entregadores.
- Não tem entendimento exato dos motivos que levaram os entregadores a desistir da plataforma.

#### Hobbies

Viajar; leitura; aprender novos idiomas; esportes.

#### Motivações

Liderança; conhecimento; Ter flexibilidade na carreira; Impactar os clientes com os resultados de seus projetos.

## Cleyton Soares



AGE	21
EDUCATION	Ensino Médio completo
STATUS	Solteiro
OCCUPATION	Entregador de delivery
LOCATION	São Paulo
TECH LITERATE	Média

“ Há 2 anos estou na empresa de delivery como entregador. E com isso desenvolvi uma boa comunicação e relação com os clientes.

### Personalidade

Extrovertido Responsável

### Biografia

Cleyton mora na Zona Leste de São Paulo. Terminou seu Ensino Médio em 2019. Entrou para Rappi para trabalhar como entregador após ser demitido durante a pandemia. É um jovem bem extrovertido e comunicativo. Gosta de bater-papo com os amigos.

### Necessidades

- Maximizar os ganhos na plataforma
- Ter mais pedidos de entregas concluídos
- Contratação de seguros de vida da empresa de delivery

### Frustração

- Insatisfação quando o cliente cancela o pedido
- Aplicativo da empresa mostra a rota do GPS diferente do local desejado
- Sua remuneração é desproporcional ao valor da inflação da gasolina

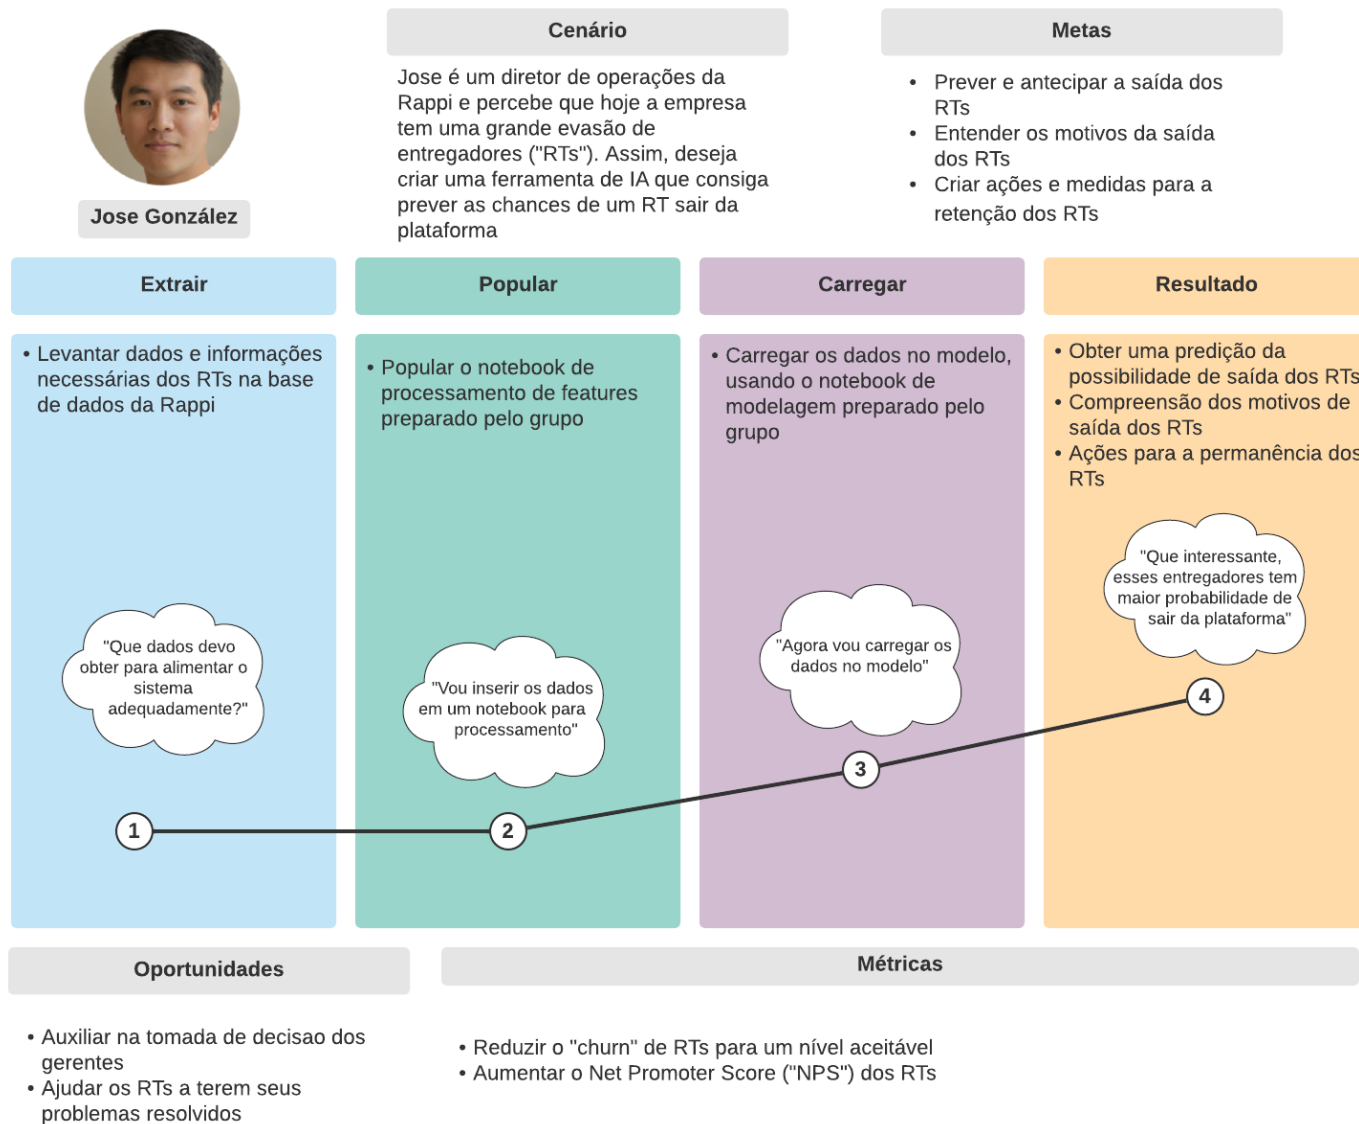
### Hobbies

Esportes; Assistir séries; jogar games eletrônicos; ir à praia.

### Motivações

Iniciativa; determinação e pontualidade em entregar os produtos pedidos pelos clientes.

## 4.1.7. Jornada do Usuário



## 4.2. Compreensão dos Dados

### 4.2.1. Descrição Geral dos Dados

Os dados disponibilizados pelo cliente consistem em diversos arquivos "Comma-separated values" ("CSV"), elencados na tabela abaixo. Segundo informações repassadas pela Rappi, todos os dados foram obtidos através do aplicativo. Também descrevemos na tabela o que cada arquivo representa, em geral, e o seu tamanho, com número de linhas e de colunas.

Nome do CSV	Descrição Geral do Conteúdo	Número de Linhas	Número de Colunas
2022-08-10 10_40am	A distância (em km) que o entregador percorreu para entregar cada pedido	31.382.215	4
attendance rate	Taxa de aceitação dos pedidos. Ex: tocou 10 vezes, aceitei 9, 90%	653.167	2
comp defects	Hoje, sempre que um usuário abre alguma reclamação sobre algum pedido incompleto, faltante, item errado.	6.783.958	10
criacao contas churn-002	Data de criação das contas churn do período	32.568.384	9
earnings	Receita de cada entregador	566.099	4
Incidentes_Regras RT	Existem diversas regras para melhoria da qualidade da operação. Exemplo: A regra 92/93 remove/libera o RT do pedido caso ele não esteja em movimento ou em direção ao cliente. (Reforço que não temos informação sobre a localização do RT, apenas se esta	2.405.601	9

	diminuindo o ETA ou não).		
infos gerais	Informações gerais do entregador	180.178	25
Ordens Done e Cancel	ordens realizadas e ordens canceladas; Ordens podem ser canceladas por qualquer razão: pela loja, falta de produto, pelo RT (Pneu furado, roubo, acidente, problemas pessoais, etc).	653.166	4
Product return	Retorno de produto uma vez que a ordem foi cancelada. Ex: comprei itens de supermercado e por qualquer razão ordem foi cancelada; o RT precisa retornar este a loja (nem todas aceitam, ponto ruim) ou devolver em algum ponto de apoio Rappi; Até isso acontecer, ele fica com uma dívida no valor dos produtos;	41.535	11
supply	Tempo em Horas que o RT fica/ficou conectado no período;	124.526	10
tempo resolucao e modal 2	Quanto tempo o entregador ficou esperando resolução para algum pedido aberto junto ao suporte Central Rappi	32.568.384	9

Mais especificamente, podemos destacar o que cada coluna significa nos arquivos CSV, conforme pode ser visto na tabela abaixo:

CSV	Nome da Coluna	Descrição	Tipo
2022-08-10 10_40am	ORDER_ID	ID do pedido	int64
2022-08-10 10_40am	STOREKEEPER_ID	ID do entregador	float64

2022-08-10 10_40am	DISTANCE_TO_USER	Distância (em KM) do usuário que fez o pedido	float64
2022-08-10 10_40am	BUNDLE_ID	ID do "pacote" de pedidos	object
attendance rate	STOREKEEPER_ID	ID do entregador	float64
attendance rate	ACCEPTANCE_RATE	Porcentagem de pedidos aceitos pelo entregador em relação ao total de pedidos recebidos	float64
comp defects	STOREKEEPER_ID	ID do entregador	float64
comp defects	WEEK	Segunda-feira da semana em referência (YYYY-MM-DD)	object
comp defects	CITY	Cidade	object
comp defects	LEVEL_ID	ID do nível do entregador	float64
comp defects	LEVEL_NAME	Nome do nível do entregador	object
comp defects	ORDERS	Número de pedidos que aconteceu algum problema	int64
comp defects	GMV_TOTAL	Total da transação (GMV = custo total pago pela Rappi para a loja)	float64
comp defects	COMPENSATIONS	Valor pago (devolvido) para o usuário	float64
comp defects	ID_COMPENSATIONS	ID do pedido que deu problema e foi compensado	float64
comp defects	DEFECT_ORDER	ID do pedido que deu problema e foi compensado	float64
criacao contas churn-002	ID	ID do entregador	int64
criacao contas churn-002	FIRST_NAME	Nome do entregador	object
criacao contas churn-002	GENDER	Gênero do entregador	object
criacao contas churn-002	CITY	Cidade de atuação	object
criacao contas churn-002	SK.CREATED_AT::DATE	Data de cadastro da conta	object

criacao contas churn-002	TRANSPORT_MEDIA_TYPE	Modal de transporte	object
criacao contas churn-002	CARTAO	Tem cartão pré-pago?	object
criacao contas churn-002	LEVEL_NAME	Nível do entregador	object
criacao contas churn-002	FECHA_ULT	Última data em que o entregador teve alguma interação com o aplicativo	object
earnings	STOREKEEPER_ID	ID do comerciante	int64
earnings	MONTH	Primeiro dia do Mês, em formato ISO-8601	object
earnings	EARNINGS	Receita do entregador	float64
earnings	TIPS	Gorjetas do entregador	float64
Incidentes_Regras RT	DATE	Data do Incidente (formato YY-MM-DD)	object
Incidentes_Regras RT	NAME	Nome do Incidente	object
Incidentes_Regras RT	INCIDENT_ID	ID do incidente	int64
Incidentes_Regras RT	STOREKEEPER_ID	ID do entregador	int64
Incidentes_Regras RT	PUNISHMENT_MINUTES	Minutos de suspensão	int64
Incidentes_Regras RT	PUNISHMENT_TYPE	Tipo de punição (permanent_block, temporary_block, warning)	object
Incidentes_Regras RT	DISCIPLINE_RULE_BUCKET	É uma derivada de um indicador interno da Rappi	object
Incidentes_Regras RT	CATEGORY_RULE	Gênero da regra aplicável	object
Incidentes_Regras RT	ORDER_ID	ID do pedido	float64
infos gerais	ID	ID do entregador	int64
infos gerais	NOME	Nome	object
infos gerais	SOBRENOME	Sobrenome	object
infos gerais	GENERO	Gênero	object
infos gerais	DATA_NASCIMENTO	Data de Nascimento	object
infos gerais	CIDADE	Cidade de atuação	object
infos gerais	IS_ACTIVE	Se o entregador está ativo ou não	bool
infos gerais	TRANSPORTE	Modal de transporte	object
infos gerais	AUTO_ACEITE	Se o entregador aceita pedidos automaticamente	bool

infos gerais	COUNT_ORDERS_LAST_7D	Ordens realizadas nos últimos 7 dias	int64
infos gerais	COUNT_ORDERS_LAST_30D	Ordens realizadas nos últimos 30 dias	int64
infos gerais	COUNT_ORDERS_CANCELED_LAST_7D	Ordens canceladas nos últimos 7 dias	int64
infos gerais	COUNT_ORDERS_CANCELED_LAST_30D	Ordens canceladas nos últimos 30 dias	int64
infos gerais	GORJETA	Gorjetas recebidas pelo entregador	float64
infos gerais	PRIMEIRO_PEDIDO	Data do primeiro pedido entregue	object
infos gerais	ULTIMO_PEDIDO	Data do último pedido entregue	object
infos gerais	COUNT_ORDERS_RESTAURANTES	Ordens de restaurantes	int64
infos gerais	COUNT_ORDERS_MERCADO	Ordens de mercado	int64
infos gerais	COUNT_ORDERS_FARMACIA	Ordens de farmácia	int64
infos gerais	COUNT_ORDERS_EXPRESS	Ordens turbo (10min)	int64
infos gerais	COUNT_ORDERS_ECOMMERCE	Ordens e-commerce	int64
infos gerais	COUNT_ORDERS_OUTDOOR	Compras em uma loja que não está no aplicativo	int64
infos gerais	FRETE_MEDIO	Média do tempo gasto na entrega dos pedidos	float64
infos gerais	COOKING_TIME_MEDIO	Média de tempo esperando o pedido ficar pronto nos restaurantes	float64
infos gerais	ITENS_MEDIO	Média de itens nas entregas	float64
Ordens Done e Cancel	STOREKEEPER_ID	ID do comerciante	int64
Ordens Done e Cancel	ORDERS_DONE	Número de pedidos realizados	int64
Ordens Done e Cancel	ORDERS_CANCEL	Ordens totais canceladas pelo entregador	int64
Ordens Done e Cancel	CANCEL_OPS_RT	Ordens canceladas manualmente pelo time de operação	int64



		ID do	
Product return	ID_ENTREGADOR	entregador	int64
Product return	LEVEL_NAME	Nível do entregador	object
Product return	MODAL	Meio de locomoção	object
Product return	CITY	Cidade de atuação	object
Product return	CREATED_AT	Data de cadastro	object
Product return	ORDER_ID	ID do pedido	int64
Product return	PRODUCT_RETURNS	Valor da devolução (negativo)	float64
Product return	VERTICAL_SUB_GROUP	Categoria do pedido (farmácia, mercado)	object
Product return	COUNT_TO_GMV	Abater do GMV	bool
Product return	GMV	Gross Merchandise Value	float64
Product return	STORE_ID	ID da loja	int64
supply	SUPPLY_HOURS	ID do entregador	int64
supply	CITY	Cidade de atuação	int64
supply	DATE	Dia da semana (YYYY-MM-DD)	object
supply	WEEK	Segunda-feira da semana em referência (YYYY-MM-DD)	object
supply	CREATED_CARD	Data de Criação do Cartão	object
supply	LEVEL_NAME_2	Nível do entregador	object
supply	HAVE_CARD	Tem um cartão?	bool
supply	TRANSPORT_MEDIA_TYPE	Modal de transporte	object
supply	NUM_ORDERS	Número de pedidos atendidos pelo entregador naquele dia	int64
supply	SUPPLY_HOURS	Horas em que o entregador ficou conectado no período	float64
tempo resolucao e modal 2	TICKET_ID	ID do ticket de suporte	object
tempo resolucao e modal 2	STOREKEEPER_ID	ID do entregador que abriu o ticket	int64
tempo resolucao e modal 2	LEVEL_NAME	Nível do entregador	object

tempo resolucao e modal 2	TRANSPORT_MEDIA_TY PE	Model de transporte do entregador	object
tempo resolucao e modal 2	SENT_DATA	Data de envio do ticket	object
tempo resolucao e modal 2	SENT_HOUR	Hora de envio do ticket	object
tempo resolucao e modal 2	RESPONSE_AT	Data e Hora de Resposta do ticket	object
tempo resolucao e modal 2	RESPONSE_TIME	Tempo de resposta (em minutos)	int64
tempo resolucao e modal 2	RESOLUTION_TIME	Tempo de resolução (em minutos)	float64
tempo resolucao e modal 2	RESOLUTION_TIME_BUCKET	Categoria de tempo de resposta	object
tempo resolucao e modal 2	CITY	Cidade do entregador	object

### Forma de agregação e mesclagem de dados:

Todos os arquivos CSV tem uma coluna com um ID único do entregador (geralmente a coluna tem o nome "STOREKEEPER\_ID", mas em alguns CSVs pode ter um nome diferente como "ID\_ENTREGADOR"). Desse modo, podemos usar esse identificador único para juntar as diferentes tabelas (fazer um "join") e assim cruzar as informações de um CSV com o outro.

### Riscos e contingências relacionados aos dados (qualidade, cobertura/diversidade e acesso):

Em relação a qualidade, temos o risco que os arquivos repassados possam ter dados que não são verossímeis por uma série de motivos (inserções errôneas, importações indevidas, "bugs" no aplicativo ou base de dados). Adicionalmente, podemos verificar um nível elevado de ruído em alguns arquivos CSV, como informações ausentes (campos nulos), muitos outliers inconsistentes (por exemplo, muitos entregadores com receitas além do esperado no arquivo "earnings") e valores repetidos (especialmente no arquivo "criacao contas churn").

Sobre cobertura e diversidade, temos alguns arquivos com muitas informações, como o "criacao contas churn" com mais de 32 milhões de registros. Isso pode levar a um excesso de informações para tratamento e análise, caso não seja feito um cruzamento e filtragem prévios.

Finalmente, no que concerne ao acesso, a Rappi não pode liberar alguns dados, como as regras automáticas usadas para aplicar suspensões e avisos na plataforma (por exemplo, quanto

tempo um entregador pode ficar parado até receber um aviso). Assim, isso pode dificultar algumas análises.

### Seleção do subconjunto para análises iniciais:

Temos algumas hipóteses iniciais sobre as causas do "churn", que irão embasar nossas análises iniciais. Identificamos essas hipóteses a seguir, junto com o conjunto de dados relevante:

- *Hipótese 1: Os entregadores ("RT"s) deixam a plataforma por muitas suspensões recorrentes.*
  - Subconjunto relevante: arquivo "Incidentes\_Regras RT", com as suspensões. Verificar se existe uma relação entre número e duração de suspensões e "churn".
- *Hipótese 2: Os entregadores deixam a plataforma por devoluções excessivas de pedidos, que levam a dívidas no valor dos produtos e custos com devoluções (gasolina, tempo de deslocamento).*
  - Subconjunto relevante: arquivo "comp defects", com as devoluções pendentes. Verificar se existe uma relação entre devoluções e "churn".
- *Hipótese 3: Os entregadores deixam a plataforma por baixa remuneração ou poucos pedidos.*
  - Subconjunto relevante: arquivos "earnings", "Ordens done e cancel" e, especialmente, "Infos gerais". Verificar se existe uma relação entre rendimentos, número de ordens realizadas e "churn".

**Restrições de segurança:** foi mencionado que são dados sensíveis e que devem ser geridos com cuidado. Portanto, não vamos publicar essa base de dados, nem repassar essas informações para terceiros. O uso dos dados será exclusivamente para desenvolver um modelo preditivo para a possibilidade de "churn" de entregadores na plataforma Rappi.

## 4.2.2. Estatística Descritiva dos Dados

Link para o Google Colab com o código das análises:

<https://colab.research.google.com/drive/1s7qv2MbyDceq2NBiZt31mBhXniZ3x8j5?usp=sharing>

A partir dos dados fornecidos, podemos estabelecer algumas análises pautadas em estatística descritiva e elaborar gráficos para testar as hipóteses suscitadas inicialmente.


- *Hipótese A: Os entregadores deixam a plataforma por baixa remuneração ou poucos pedidos*

Para fins de comparação para essa hipótese, foi necessário trabalhar com dois grupos – os entregadores que saíram da plataforma e aqueles que permanecem na mesma. Para tanto, dividimos o arquivo "Infos Gerais" em dois grupos, os que entregaram o último pedido há mais de 21 dias ("CHURN")- critério informado em entrevista com a Rappi para classificação de Churn - e os que entregaram pedidos após essa data ("PERMANECE"):

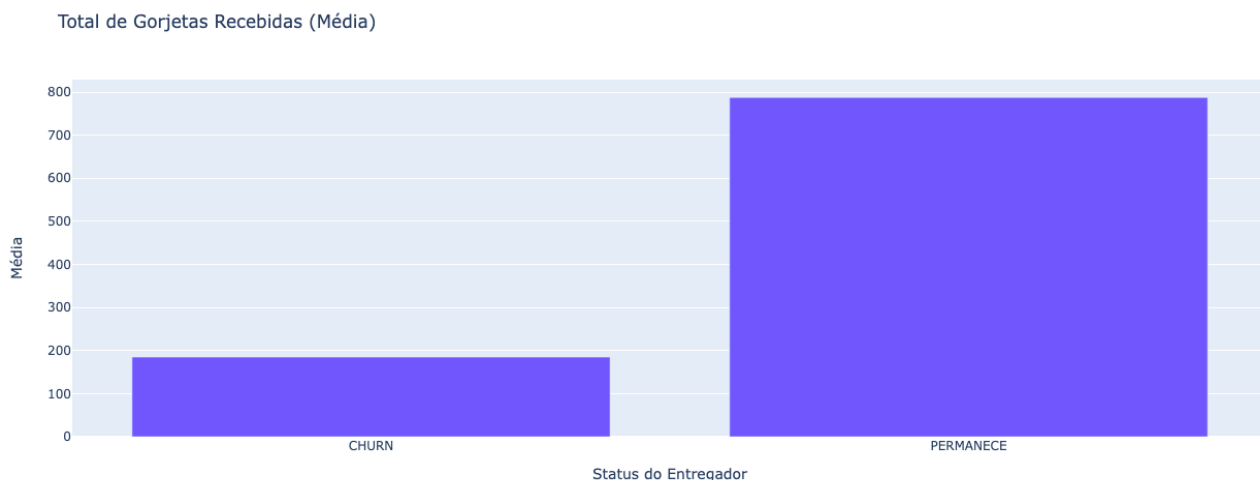
```
df_infos = pd.read_csv('/content/drive/MyDrive/data/infos gerais.csv')
df_infos.sort_values('ULTIMO_PEDIDO', ascending=False)
# Churns são entregadores com o último pedido há mais de 21 dias
# Os dados vão até 01/08/2022, logo a data de corte é 11/07/2022
df_not_churned = df_infos[(df_infos['ULTIMO_PEDIDO'] > '2022-07-11')]
df_churned = df_infos[(df_infos['ULTIMO_PEDIDO'] < '2022-07-11')]
```

Realizando uma comparação entre os dois grupos, obtivemos resultados interessantes.

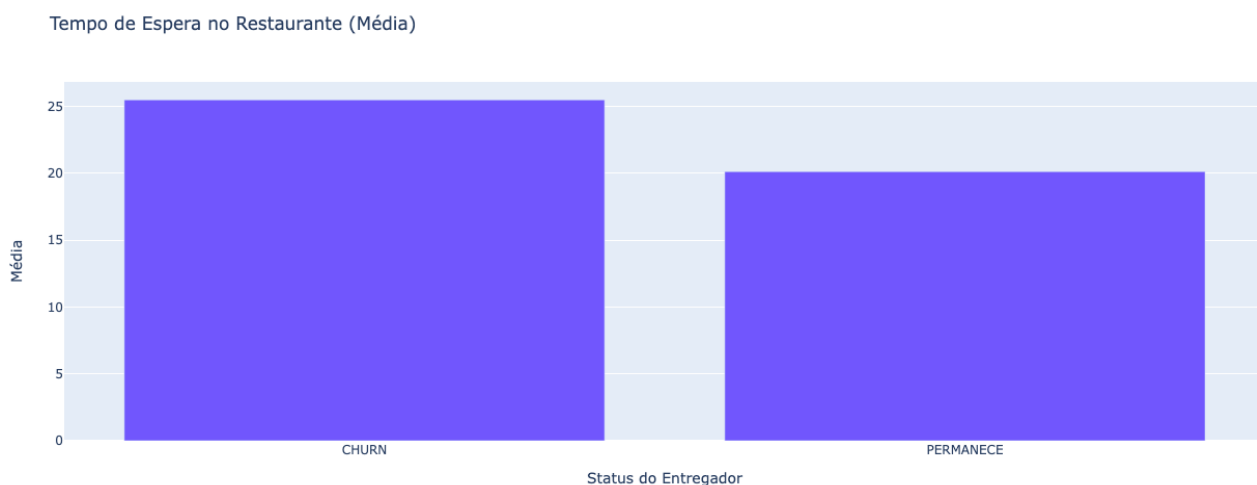
- Os entregadores que sofreram "churn" realizaram menos entregas do que aqueles que permaneceram na plataforma, sendo o número de pedidos cerca de 4 vezes maior. Isso pode ser um indicador de que quanto mais corridas o entregador recebe, menor sua propensão a sair da plataforma:



- Os entregadores que permaneceram na plataforma ganharam quase o quádruplo de gorjetas daqueles que deram "churn". Isso pode indicar que as gorjetas (ou ausência delas) são um fator de permanência na plataforma:




- Entregadores que permaneceram na plataforma em geral esperam menos tempo para o pedido ficar pronto no restaurante. Não conseguimos entender qual a causa desse fator:




- Aspectos demográficos, como gênero do entregador, aparentam não impactar de forma expressiva o "churn". A composição dos dois grupos é praticamente idêntica:


Gênero dos entregadores que deram 'Churn'




Gênero dos entregadores que permaneceram na plataforma



- *Hipótese B: Os entregadores deixam a plataforma por devoluções excessivas de pedidos*
- Para trabalhar com essa hipótese, verificamos se algum grupo está representado de forma desproporcional no valor de pedidos a devolver pendentes. Assim, comparamos a quantidade de entregadores em cada nível e a quantidade de devoluções pendentes:





Nesse contexto, verificamos que há uma quantidade expressiva de devolução no nível bronze (porém proporcional), e uma quantidade muito acima do esperado no nível "rookie" e "danger". O que mais se destaca nessa análise é que o nível "bronze" pode representar um grupo descontente com a plataforma, dado o alto volume de devoluções pendentes.

#### 4.2.3. Descrição da Predição Desejada ("Target")

A predição desejada ("target") consiste em classificar se um entregador ("RT") irá sair da plataforma Rappi (evento de "churn") ou se irá permanecer na plataforma.

Diferentemente de um modelo de regressão contínua, em que se deseja encontrar um valor numérico específico por interpolação (por exemplo, o valor de uma casa em determinado mercado imobiliário), no modelo de classificação o mais importante é prever em qual categoria se deve encaixar uma situação (por exemplo, um paciente tem uma patologia ou não tem).

Nosso caso, portanto, consiste em um modelo de **classificação binária**, em que o "target" pode ser encaixado em uma de duas categorias: a) o entregador saiu; ou b) permaneceu na plataforma durante determinado período.

## 4.3. Preparação dos Dados

- Link para o notebook de "*feature engineering*":

[https://colab.research.google.com/drive/1gcgucA\\_kH5xj9dncwh1sUfaLRR0k3G?usp=sharing](https://colab.research.google.com/drive/1gcgucA_kH5xj9dncwh1sUfaLRR0k3G?usp=sharing)

Após cuidadosa análise dos dados disponibilizados pelo cliente, iniciamos a preparação e também a seleção das características, propriedades e atributos ("features") que serão utilizadas em nosso modelo preditivo. Nesta fase não nos limitamos em apenas buscar features prontas, mas também criamos novas features com base nos dados fornecidos para que pudéssemos explicitar informações valiosas, mas que não estavam visíveis nos dados.

### 4.3.1. Manipulação

Importamos as bases de dados em formato ".CSV" para nosso ambiente de desenvolvimento ("Google Colaboratory") e realizamos algumas otimizações para conseguir lidar com problemas gerados pelo tamanho das bases. As principais mudanças que realizamos foram:

- mudança de tipo de algumas variáveis, como por exemplo de int64 para int16 em algumas variáveis que não armazenam grandes valores que exigissem, portanto, grande quantidade de memória volátil ("RAM");
- mudança das variáveis categóricas de 'object' para 'category', também para economizar memória RAM;
- encoding das variáveis categóricas usando Label-Encoding (se ordinais) e One-Hot Encoding (se nominais);
- mudança de 'object' para 'datetime' nas colunas que representam datas;
- transformação dos 'datetimes' em 'ordinais', para introdução no modelo;
- renomeação de algumas colunas para nomes mais intuitivos.

### 4.3.2. Agregação

Para juntar as bases de dados realizamos algumas operações de merge através da biblioteca "pandas" da linguagem Python. Utilizamos a operação de Inner Join - que retorna um dataframe com apenas as linhas que estão presente em ambos os dataframes, concatenados através de um valor de referência (no caso, o ID dos entregadores). Utilizamos também a operação de Left Join - que retorna um dataframe com todas as linhas dos primeiro dataframe que está sendo concatenado.

Além disso, aplicamos a função "*groupby*" para conseguirmos:

- agrupar os ganhos e as gorjetas de cada entregador;



- somar os minutos de punição de cada entregador, de forma que conseguíssemos visualizar o tempo total de punição de cada ID (entregador) da base;
- realizar uma contagem, por entregador, de pedidos em aberto para o suporte, a soma de devoluções que constam como pendentes na base e, por fim, uma contagem de pedidos com problema por entregador.

### 4.3.3. Remoção e Substituição

Retirar entregadores sem earnings, Inner Join em 'earnings', 'ordens realizadas e canceladas', 'média de km rodados', 'taxa de aceitação dos pedidos'.

Fizemos também algumas operações de remoção e substituição nas bases. Através de operações de Inner join - comentadas previamente no tópico 4.3.2 - juntamos os dataframes que continham as informações de earnings, ordens realizadas e canceladas, média de km rodados e taxa de aceitação dos pedidos – removendo, assim, qualquer entregador que não possuísse qualquer um desses atributos.

Na tabela de 'taxa de aceitação dos pedidos', alguns entregadores tinham valores em branco como porcentagem de aceitação. Realizamos uma operação 'dropna' para eliminar esses entregadores.

Em outras tabelas, realizamos operações de Left Join, realizando as substituições adequadas para os valores ausentes na tabela à direita na operação de merge com o método "*fillna*" do Pandas:

- "Incidentes Regras RT" (Medidas Disciplinares contra Entregadores) – se o entregador não tinha qualquer registro na tabela de medidas disciplinares, substituímos o valor vazio de "PUNISHMENT\_MINUTES" por "0";
- "Quantidade de pedidos ao suporte da Rappi"- se o entregador não tinha qualquer registro na tabela de pedidos de suporte, substituímos o valor vazio de "SUPPORT\_TICKET\_COUNT" contagem por "0";
- "Devoluções Pendentes" – se o entregador não tinha qualquer devolução pendente na tabela, substituímos o valor "PRODUCT\_RETURNS" por "0";
- "Pedidos com Problema" – se o entregador não tinha qualquer pedido com problema em seu ID, substituímos o valor "DEFECTS\_COUNT" por "0".

### 4.3.4. Seleção das features

Nome da feature escolhida	Motivo
LEVEL_NAME	É relevante, pois após o merge com outras tabelas, nos permite verificar se contas com níveis mais baixos dão mais churn.

TRANSPORT	É relevante, pois conseguimos verificar se há algum modal em que os entregadores dão mais churn
	AUTO_ACCEPT
	ACCEPTANCE_RATE
	ORDERS_DONE
	ORDERS_LAST_30D_COUNT
	ORDERS_CANCEL
	ORDERS_CANCELED_LAST_30D_COUNT
	FIRST_ORDER_DATE
	LAST_ORDER_DATE
	EARNINGS
TIPS	É relevante, pois conseguimos realizar um agrupamento por STOREKEEPER_ID, nos permitindo verificar se entregadores com menos gorjetas dão mais churn.
PUNISHMENT_MINUTES	É relevante, pois conseguimos realizar um agrupamento por STOREKEEPER_ID, nos permitindo verificar se entregadores com mais minutos de punição dão mais churn.
PRODUCT_RETURNS	É o valor da devolução em um pedido cancelado, pode ser útil para visualizarmos se tem alguma relação na devolução de compras de maior volume, com o churn.


SUPPORT_TICKET_COUNT	É relevante, pois conseguimos realizar um agrupamento por STOREKEEPER_ID, nos permitindo verificar se os entregadores que abrem mais "chamados" para o suporte da Rappi dão mais churn.
DEFECTS_COUNT	É relevante, pois conseguimos realizar um agrupamento por STOREKEEPER_ID, nos permitindo verificar se os entregadores com mais "ordens problemáticas" dão mais churn.
AVG_DISTANCE_TO_USER	É relevante, pois conseguimos realizar um agrupamento por STOREKEEPER_ID, nos permitindo entender se entregadores com pedidos mais longos dão mais churn.

Ao invés de realizarmos uma análise gráfica exploratória para cada uma das features acima, optamos por construir um modelo preliminar usando regressão logística (disponível em <https://colab.research.google.com/drive/1kowwKCfPTIs6mnsk5RbLtMWLaypdAG3D#scrollTo=OJyQcGeaRkWg>) para demonstrar como podemos apresentar as hipóteses mais pertinentes através de um modelo. Os resultados obtidos foram os seguintes:

```

Feature: LEVEL_NAME, Score: 0.05326
Feature: AUTO_ACCEPT, Score: 0.06191
Feature: ACCEPTANCE_RATE, Score: 0.12545
Feature: ORDERS_DONE, Score: -0.06278
Feature: ORDERS_LAST_30D_COUNT, Score: -2.50861
Feature: ORDERS_CANCEL, Score: 0.07066
Feature: ORDERS_CANCELED_LAST_30D_COUNT, Score: -0.13663
Feature: FIRST_ORDER_DATE, Score: -0.02853
Feature: LAST_ORDER_DATE, Score: -12.97138
Feature: EARNINGS, Score: 0.22665
Feature: TIPS, Score: 0.48481
Feature: PUNISHMENT_MINUTES, Score: 0.25026
Feature: PRODUCT_RETURNS, Score: 0.04352
Feature: SUPPORT_TICKET_COUNT, Score: 21.75265
Feature: DEFECTS_COUNT, Score: -0.72360
Feature: AVG_DISTANCE_TO_USER, Score: 0.02992
Feature: TRANSPORT_bicycle, Score: 0.01427
Feature: TRANSPORT_car, Score: -0.02671
Feature: TRANSPORT_motorbike, Score: 0.00896
Feature: TRANSPORT_neither, Score: -0.11032
Feature: TRANSPORT_cargo_van, Score: 0.00927
Feature: TRANSPORT_motorbike_trailer, Score: 0.00000

```



No gráfico acima, quanto *mais negativo* o valor da feature em questão, *menos* propenso um entregador é de dar "churn" se tiver um valor alto naquela feature. Inversamente, quanto *mais positivo* o valor da feature no gráfico acima, *mais propenso* um entregador é de dar "churn" se tiver um valor alto naquela feature.

No caso, se observa um valor muito negativo para "LAST\_ORDER\_DATE", ou seja, quanto mais tempo um entregador fica sem entregar um pedido, mais cresce sua chance de dar "churn". Isso pode representar um viés, porém, pois uma das definições de "churn" que aplicamos é a de um entregador que está há mais de 21 dias sem realizar entregas.

Outro ponto de destaque é o valor muito positivo para "SUPPORT\_TICKET\_COUNT". Isso representa o número absoluto de chamados abertos por um entregador para o suporte da Rappi. Todavia, entendemos que esse dado pode representar um ruído, pois em uma análise manual notamos que os entregadores que não deram "churn" estão sem *nenhum* ticket aberto para o suporte, o que é um forte indício de que se trata de um dado enviesado:

```
df_infos.groupby('IS_CHURN')['SUPPORT_TICKET_COUNT'].describe()
```

	count	mean	std	min	25%	50%	75%	max
IS_CHURN								
False	31133.0	0.000000	0.000000	0.0	0.0	0.0	0.0	0.0
True	132160.0	12.544597	31.301608	0.0	0.0	2.0	12.0	1184.0

## 4.4. Modelagem

Para o teste de todo modelo preditivo, os dados foram divididos em duas parcelas: dados de treino, e dados de teste, em uma proporção de 70% e 30%, respectivamente.

Realizamos um “undersampling” durante o processo de modelagem com a biblioteca “imbalanced-learn”, pois o conjunto de dados de entregadores que deram “churn” era consideravelmente superior ao dos que permaneceram na plataforma. Esse tratamento essencialmente consiste em eliminar parte do conjunto com dados em excesso para equilibrá-lo com o de dados sub representados. Caso esse tratamento do desbalanceamento identificado não fosse realizado, isso poderia enviesar as métricas apresentadas a seguir.

Também excluimos as features ‘ORDERS\_LAST\_30D\_COUNT’ e ‘LAST\_ORDER\_DATE’, pois poderiam enviesar o modelo ao fornecer dicas muito fortes de um entregador prestes a dar churn. Um entregador que realizou poucas ordens nos últimos 30 dias ou ficou muitos dias sem realizar uma ordem seria classificado como churn extremamente provável e traria um viés excessivo para o modelo. Outra feature removida foi ‘SUPPORT\_TICKET\_COUNT’, pois por algum motivo os entregadores que não deram churn estavam com essa métrica zerada, o que também traz um viés excessivo para o modelo.

Passada essa análise preliminar, utilizamos, majoritariamente, quatro métricas de avaliação, cada uma tendo sua peculiaridade. Vale ressaltar que esses indicadores se baseiam na “matriz de confusão”, uma matriz que compara as predições falsas e positivas, com o dado real do target.

		Detectada	
		Sim	Não
Real	Sim	Verdadeiro Positivo (VP)	Falso Negativo (FN)
	Não	Falso Positivo (FP)	Verdadeiro Negativo (VN)

Matriz de confusão

**Acurácia:** Indica a performance geral do modelo, apresentando uma porcentagem de quantas classificações o modelo classificou corretamente.

**Precisão:** Indica quantos dos positivos feitos pelo modelo foram realmente assertivos.

**Revocação/Recall:** Indica quantos dos positivos dados pelo modelo foram verdadeiros ou falsos.

**F1 Score:** É a média harmônica entre precisão e recall ( $2 * \text{precisão} * \text{recall} / (\text{precisão} + \text{recall})$ ).

Para fins de aprofundamento, as fórmulas para cálculo de cada uma das métricas já foram mencionadas na seção 4.1.3.

Dentre as quatro principais métricas de avaliação de modelos, demos prioridade a duas, acurácia e recall. Basicamente, buscamos um modelo com uma alta taxa de acertos, por isso priorizamos a acurácia. Também desejamos o menor número possível de falso negativos, por valorizamos o recall sobre a precisão, dado que é mais importante que o modelo identifique todos os entregadores propensos a dar churn ("recall") do que prevenir a identificação incorreta como churn um entregador que na realidade não é churn ("precisão").

Para termos um sentido inicial dos modelos que poderiam apresentar as melhores métricas, usamos a biblioteca Pycaret. Essa ferramenta possibilita rodar uma série de modelos de classificação e observar as métricas de cada um, para que possamos escolher o modelo mais adequado para implementar manualmente.

Atualmente, após o teste com vários algoritmos, elegemos os quatro melhores em termos de acurácia, sendo eles, Light Gradient Boosting Machine (LightGBM), Random Forest Classifier, Gradient Boosting Classifier e Ada Boost Classifier. No caso específico do modelo Extra Trees Classifier, optamos por excluí-lo pelo fato de ser muito semelhante ao Random Forest. Abaixo estão as métricas de cada modelo, com a Acurácia, Revocação, Precisão e F1 Score.

A tabela abaixo contém os modelos de machine learning aplicados ao nosso "dataset", em ordem decrescente de acurácia:

Modelo	Acurácia	Revocação	Precisão	F1 Score
Light Gradient Boosting Machine	0.9316	0.9623	0.9549	0.9585
Random Forest Classifier	0.9297	0.9590	0.9556	0.9573
Extra Trees Classifier	0.9269	0.9558	0.9552	0.9555
Gradient Boosting Classifier	0.9229	0.9464	0.9593	0.9528
Ada Boost Classifier	0.9165	0.9403	0.9574	0.9487
SVM - Linear Kernel	0.9023	0.9355	0.9452	0.9403
Logistic Regression	0.8889	0.9091	0.9536	0.9308

Decision Tree Classifier	0.8858	0.9149	0.9445	0.9294
K Neighbors Classifier	0.8563	0.8676	0.9533	0.9085
Ridge Classifier	0.8439	0.8598	0.9454	0.9006
Linear Discriminant Analysis	0.8439	0.8598	0.9454	0.9006
Naive Bayes	0.2562	0.0968	0.9848	0.1758
Quadratic Discriminant Analysis	0.1778	0.0000	0.0000	0.0000
Dummy Classifier	0.1778	0.0000	0.0000	0.0000

O notebook que usamos para obter a tabela acima pode ser encontrado no link a seguir:

[https://colab.research.google.com/drive/1\\_I8X6shyH90NFIJso10Mw7Lq\\_NReoq6m#scrollTo=58ZtXVvXFGas](https://colab.research.google.com/drive/1_I8X6shyH90NFIJso10Mw7Lq_NReoq6m#scrollTo=58ZtXVvXFGas)

É importante observar que as métricas apresentadas no teste automatizado são diferentes da seção 4.5 com os modelos feitos manualmente, pois os "datasets" de treino e teste são sorteados aleatoriamente e, portanto, irão divergir. Além disso, a biblioteca Pycaret realiza alguns ajustes que optamos por fazer de forma diferente quando fizemos a construção dos modelos de forma manual.

Apesar disso, essa é uma excelente forma de avaliar quais modelos apresentam os resultados mais promissores e serviu para embasar a seleção dos modelos para avaliação manual.



## 4.5. Avaliação

A partir dos resultados obtidos na seção 4.4 com a modelagem e testes preliminares, pudemos selecionar os modelos mais promissores para avaliação e implementação manual, no notebook linkado a seguir:

<https://colab.research.google.com/drive/1kowwKCfPTIs6mnsk5RbLtMWLaypdAG3D#scrollTo=OJyQcGeaRkWg>

Treinamos cada um dos modelos manualmente e verificamos para cada um a:

1. acurácia de treino e de teste;
2. revocação;
3. precisão;
4. F1 score;
5. matriz de confusão; e
6. importância de cada feature para o modelo.

Dessa forma, podemos verificar a qualidade dos resultados obtidos e a taxa de erro, constatando se os resultados preliminares do Pycaret estão de acordo com os modelos do scikit-learn.

Observa-se que os algoritmos escolhidos na seção 4.4. foram adequados pois são todos destinados para tarefas de *classificação* – que é o problema de negócio enfrentado pelo cliente, como apontado na seção 4.1.3. A própria biblioteca que usamos para testes preliminares (Pycaret) apenas usa modelos relacionados com essa tarefa, como pode ser visto na linha de importação do módulo relevante (`from pycaret.classification import *`).

Sendo assim, vamos passar a avaliar os modelos e seus resultados.

### LightGBM

LightGBM é uma estrutura de aumento de gradiente que usa uma série de árvores de decisão para embasar suas escolhas ("ensemble"). Ele pode ser usado para tarefas de classificação ou outras tarefas de machine learning.

Esse modelo retornou em geral métricas muito boas e deu bastante importância para as features de ordens canceladas e defeitos nas ordens.

```
Acc treino: 0.9024274511762649
Acc teste: 0.9087736893792181
```

```
Revocação: 0.9205724871215774
Precisão: 0.9670514221736465
F1_score: 0.9432397295891836
```

Matriz de confusão:


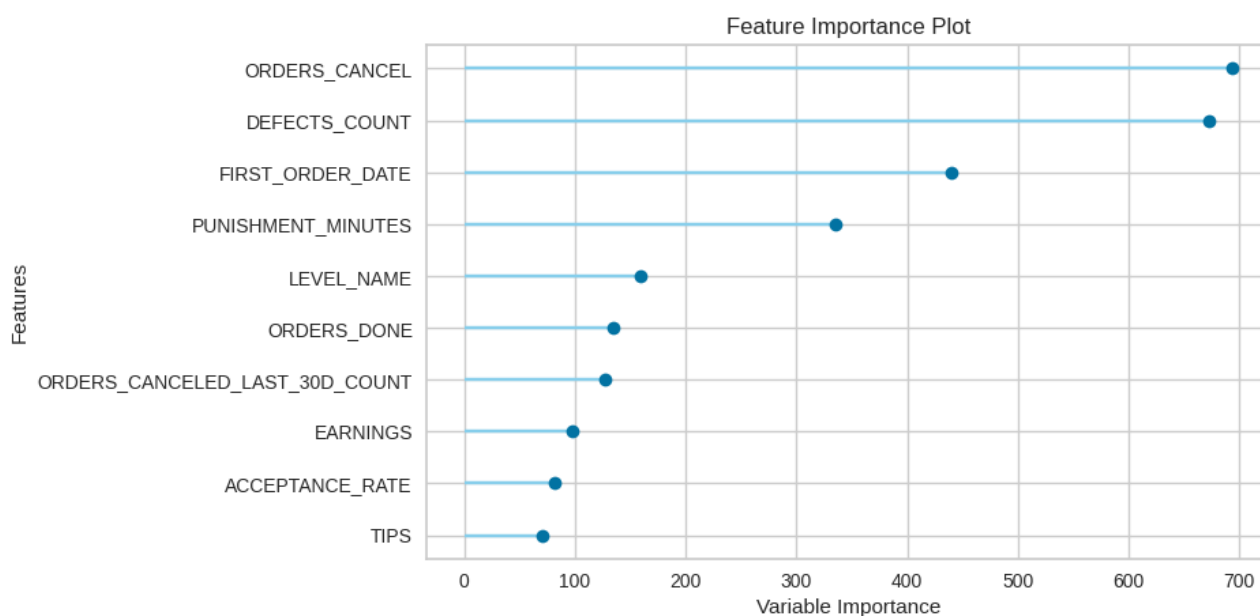


Gráfico de importância das features:



## Random Forest Classifier

Random Forest é um algoritmo de aprendizado de máquina "ensemble", que usa o resultado de diversas árvores de decisão para embasar suas decisões.

O modelo apresentou ótima acurácia, especialmente no dataset de teste. Também apresentou a melhor revocação. Porém, a precisão e acurácia no dataset de treino foram inferiores ao do LightGBM.

Esse modelo priorizou as features de ordens canceladas nos últimos 30 dias e data de entrega do primeiro pedido.

```
Acc treino: 0.8630937515608611
Acc teste: 0.9185524143839194
```

```
Revocação: 0.9417163259661563
Precisão: 0.9526631734242255
F1_score: 0.947158121009041
```

Matriz de confusão:





Gráfico de Importância das Features:



Gradient Boosting Classifier

Gradient Boosting, assim como LightBGM, é um algoritmo de aumento de gradiente baseado em árvores de decisão. Contudo, o LightBGM é comparativamente mais eficiente. Os resultados obtidos foram muito semelhantes entre esses dois algoritmos, com exceção da acurácia de treino, que foi significativamente superior no LightBGM.

```
Acc treino 0.8877428699865142
Acc teste 0.909797530245095
```

```
Revocação 0.9246834318775852
Precisão 0.9643008362443104
F1 Score 0.9440766889047217
```

Matriz de confusão:





Gráfico de importância das features:



## AdaBoost

AdaBoost é uma sigla para "Adaptive Boosting". É um algoritmo de aprendizado de máquina muito usado para tarefas de classificação binária. Ele usa uma série de algoritmos de aprendizado mais "fracos" e consolida seus resultados para obter uma decisão mais robusta.

```
Acc treino: 0.8789770740722241
Acc teste: 0.9094632148603189
```

```
Revocação: 0.9267642804577867
Precisão: 0.9618889591234724
F1_score: 0.9440000000000001
```

Matriz de confusão:


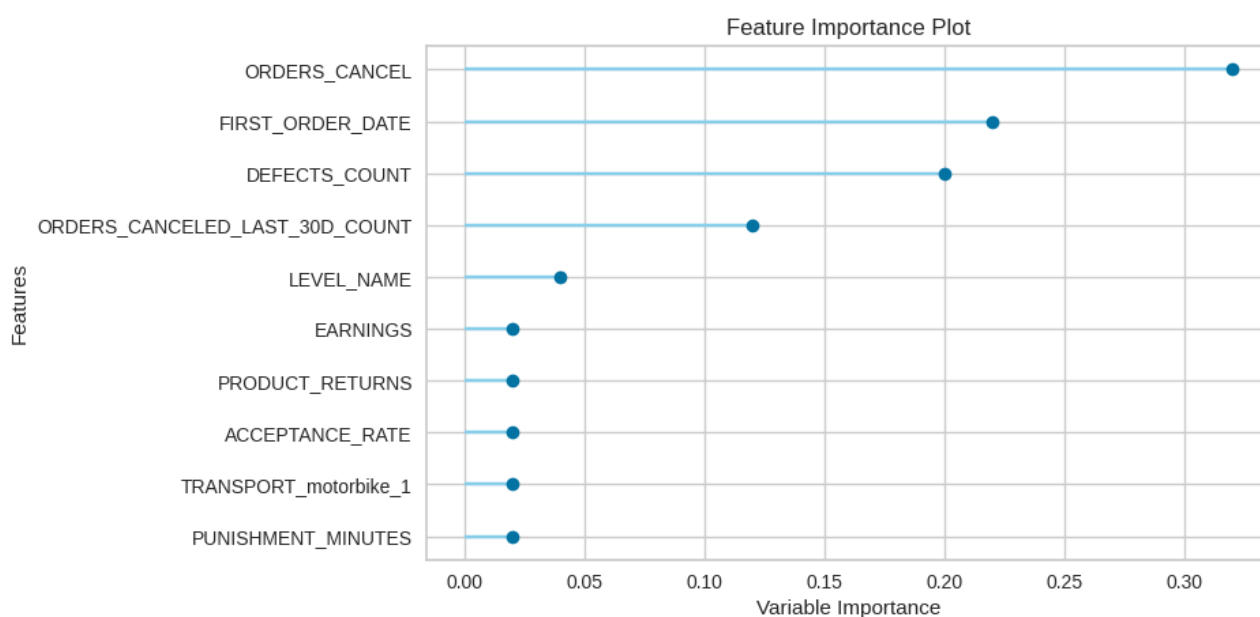


Gráfico de importância das features:



**Conclusão:** Todos os algoritmos escolhidos para avaliação foram adequados e confirmaram os resultados obtidos nos testes preliminares. Todos apresentaram acurácia acima de 85% e taxas de revocação, precisão e score F1 acima de 90%. As matrizes de confusão também apontam que os dados não estão viciados, devido a correção feita com o "undersampling".

## 4.6 Comparação de Modelos

## 5. Conclusões e Recomendações

Escreva, de forma resumida, sobre os principais resultados do seu projeto e faça recomendações formais ao seu parceiro de negócios em relação ao uso desse modelo. Você pode aproveitar este espaço para comentar sobre possíveis materiais extras, como um manual de usuário mais detalhado na seção “Anexos”.

Não se esqueça também das pessoas que serão potencialmente afetadas pelas decisões do modelo preditivo, e elabore recomendações que ajudem seu parceiro a tratá-las de maneira estratégica e ética.



## 6. Referências

Nesta seção você deve incluir as principais referências de seu projeto, para que seu parceiro possa consultar caso ele se interessar em aprofundar.

Utilize a norma ABNT NBR 6023 para regras específicas de referências. Um exemplo de referência de livro:

SOBRENOME, Nome. **Título do livro**: subtítulo do livro. Edição. Cidade de publicação: Nome da editora, Ano de publicação.

## Anexos

Utilize esta seção para anexar materiais como manuais de usuário, documentos complementares que ficaram grandes e não couberam no corpo do texto etc.